Ludwig-Maximilians-Universität München

Wintersemester 2025/26

Veranstaltung: Empra 2: Formal Modeling of Psychological Theories

Formalisiertes Teilmodell des Online-Disinhibition-Effekts nach Suler (2004)

Matrikelnummer: 12803211

Datum: 17. März 2026

Zielsetzung

Ziel dieser Arbeit ist die exemplarische Formalisierung einer psychologischen Theorie zum Online-Disinhibition-Effekt nach Suler (Suler (2004)). Ausgehend von einem fokussierten Teil der Theorie werden zentrale Konstrukte identifiziert, im VAST-Display strukturiert und in ein formales Modell mit expliziten funktionalen Beziehungen überführt. Anschließend wird geprüft, ob das Modell das Zielphänomen — stärkeres disinhibiertes Verhalten bei hoher Dissociative Anonymity und hoher Invisibility — in einer Simulation reproduziert. Im Mittelpunkt steht die methodisch korrekte und transparente Anwendung der Formalisierungsschritte, nicht die vollständige Formalisierung der Gesamttheorie.

Kurze verbale Einführung in die Theorie (Suler)

Suler beschreibt Online-Disinhibition als Folge spezifischer Eigenschaften computervermittelter Kommunikation, die Hemmmechanismen reduzieren und dadurch benigne wie toxische Formen enthemmten Verhaltens begünstigen können (Suler (2004)). Mehrere Merkmale des Cyberspace — etwa dissociative anonymity, invisibility, asynchrony oder minimization of status and authority — werden als Auslöser nachgelagerter kognitiver und sozialer Prozesse verstanden. Das hier formal spezifizierte Teilmodell fokussiert auf Dissociative Anonymity (DisAn) und Invisibility (Inv) und beschreibt, wie diese Kontextbedingungen über vermittelnde Prozesse zu erhöhter momentaner Disinhibition und beobachtbarem Online-Verhalten führen.

Zentrale Konstrukte der Theorie (im VAST-Modell)

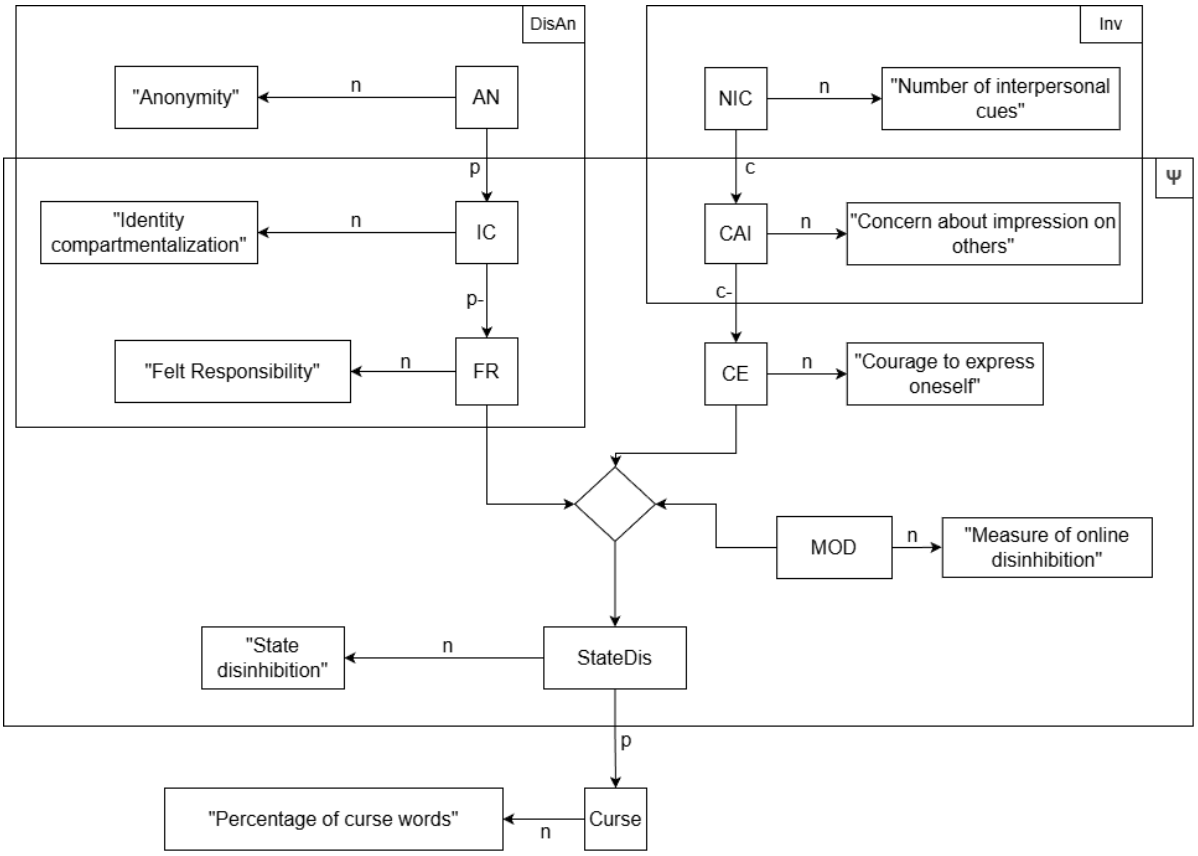

Abbildung 1: VAST-Display des fokussierten Teilmodells des Online-Disinhibition-Effekts.

Im VAST-Modell werden zwei von Suler beschriebene Eigenschaften des Cyberspace als exogene Kontextvariablen modelliert: Dissociative Anonymity und Invisibility. Dissociative Anonymity wird über AN operationalisiert, Invisibility über NIC (*number of interpersonal cues*), wobei niedrige NIC-Werte hoher Invisibility entsprechen. Als vermittelnde Konstrukte werden Identity Compartmentalization (IC), Felt Responsibility (FR), Concern about Impression on Others (CAI) und Courage to Express Oneself (CE) berücksichtigt. Zusätzlich wird MOD als exogene Dispositionsvariable aufgenommen, um interindividuelle Unterschiede in der allgemeinen Tendenz zu enthemmtem Verhalten abzubilden. Als beobachtbarer Verhaltensindikator dient exemplarisch der Schimpfwortanteil (Curse). Detaillierte Definitionen, Quellenzitate und Verknüpfungs-IDs sind in Appendix A dokumentiert.

Eingrenzung des Scopes und Begründung

Die Formalisierung konzentriert sich auf Dissociative Anonymity und Invisibility, weil beide im Originalartikel als zentrale Erklärungsmechanismen des Online-Disinhibition-Effekts hervorgehoben werden (Suler (2004)). Anonymität wird von Suler ausdrücklich als einer der ‚principal factors' hervorgehoben, weil sie die Trennung zwischen Online-Handlung und Offline-Identität erleichtert und

damit Vulnerabilität bei Selbstoffenbarung oder normabweichendem Verhalten reduziert. Invisibility wird als wesentlicher Mechanismus dargestellt, weil fehlender Blickkontakt sowie der Wegfall nonverbaler Rückmeldesignale soziale Hemmungen senken und Ausdrucksbereitschaft erhöhen können (Suler (2004)). Zugleich lassen sich beide Mechanismen vergleichsweise klar operationalisieren: Dissociative Anonymity über den Grad der Identifizierbarkeit (Christie & Dill (2016)), Invisibility über die Anzahl interpersonaler Hinweisreize. Auf dieser Grundlage wird eine theoriegeleitete Prozesskette spezifiziert, die Kontextbedingungen, vermittelnde Mechanismen, State Disinhibition und ein beobachtbares Verhaltensmaß verbindet. Die vollständige Construct Source Table befindet sich in Appendix A; die Variable Table und die Relationships Table in Appendix B bzw. C.

Phänomen und Robustheit

Phänomen

Das zu erklärende Phänomen lautet: Bei hoher Dissociative Anonymity und hoher Invisibility tritt mehr Online-Disinhibition auf als bei niedriger Ausprägung dieser Kontextbedingungen.

Hypothesen

Aus dem fokussierten Teilmodell ergeben sich drei Erwartungen für den Outcome-Indikator *Curse*: Erstens sollte höhere Anonymität (AN) mit höherem *Curse* einhergehen. Zweitens sollte höhere Hinweisreiz-Dichte (NIC/cues) mit niedrigerem *Curse* verbunden sein, sodass hohe Invisibility bei niedrigen NIC-Werten zu mehr *Curse* führt. Drittens wird erwartet, dass der Effekt von Anonymität unter niedrigen NIC/cues stärker ausfällt. Auf Ebene von StateDis wird zudem ein positiver Zusammenhang mit MOD und ein negativer Zusammenhang mit *base_resp* (über FR) angenommen.

Evidenzbasis und Stärke der Evidenz

Als Evidenzbasis werden eine Meta-Analyse zu benigner Disinhibition sowie zwei Arbeiten zu aggressionsnäheren Outcomes herangezogen. Clark-Gordon et al. berichten in einer Random-Effects-Meta-Analyse ($k = 14$) einen kleinen positiven Zusammenhang zwischen Online-Anonymität und Selbstoffenbarung ($r = .184$, 95% CI [.04, .33]), zugleich aber eine sehr hohe, nicht erklärte Heterogenität ($I^2 = 92.79\%$) (Clark-Gordon, Bowman, Goodboy, & Wright, 2019). Für die vorliegende Fragestellung ist daher vor allem die Richtung des Zusammenhangs informativ, weniger seine genaue Größe.

Ergänzend untersuchten Lapidot-Lefler und Barak in einem 2×2×2-Experiment toxische Online-Disinhibition anhand mehrerer Flaming-Indikatoren. Dabei zeigten sich kleine Effekte einzelner Online-Faktoren, etwa für Anonymität auf „threats“ und für Invisibility auf negative Atmosphäre, während fehlender Eye-Contact teilweise den stärksten Einfluss hatte (Lapidot-Lefler & Barak, 2012). Dies spricht dafür, dass disinhibitionsbezogene Outcomes nicht von einem einzelnen Merkmal abhängen, sondern von konkreten Cue-Konfigurationen und dem jeweiligen Outcome. Ein systematischer Review zu Cyberbullying bei Jugendlichen berichtet zudem konsistente Zusammenhänge zwischen allgemeiner Online-Disinhibition und Cyberbullying, aber inkonsistente Befunde für die spezifische Facette Anonymität und keine klare Evidenz für Invisibility (Wang, Jiang, Zhou, Fei, & Wang, 2024).

Generalisierbarkeit (UTOS)

Die Generalisierbarkeit ist nur eingeschränkt. **Units** variieren zwischen heterogenen CMC-Stichproben und Convenience Samples (Clark-Gordon et al., 2019; Lapidot-Lefler & Barak, 2012). **Treatments** unterscheiden sich deutlich in der Operationalisierung von Anonymität und Invisibility, etwa zwischen visueller, diskursiver oder experimentell manipulierter Anonymität (Clark-Gordon et al., 2019; Lapidot-Lefler & Barak, 2012). **Outcomes** reichen von benigner Selbstoffenbarung bis zu Flaming- oder Cyberbullying-nahen Indikatoren, was die Vergleichbarkeit begrenzt (Clark-Gordon et al., 2019; Lapidot-Lefler & Barak, 2012; Wang et al., 2024). **Settings** reichen von allgemeinen computervermittelten Interaktionen bis zu kontrollierten Chat-Experimenten. Insgesamt spricht die Evidenz eher für die grundsätzliche Relevanz des Online-Kontexts als für eine stabile, kontextunabhängige Effektgröße.

Fazit

Das Phänomen kann als **eingeschränkt robust** gelten, weil meta-analytisch ein kleiner positiver Zusammenhang zwischen Anonymität und benigner Disinhibition vorliegt, die Evidenz jedoch durch hohe Heterogenität, unterschiedliche Outcome-Klassen und variierende Operationalisierungen deutlich eingeschränkt ist (Clark-Gordon et al., 2019; Lapidot-Lefler & Barak, 2012; Wang et al., 2024).

Formulierung der (Proto-)Theorie

Ausgehend vom VAST-Display wird angenommen, dass Dissociative Anonymity als Kontextmerkmal des Cyberspace über Anonymity (AN) operationalisiert werden kann und die Trennung von Online-Handeln und Offline-Identität (Identity compartmentalization; B4/B2) begünstigt. Dadurch sinkt das Erleben persönlicher Verantwortlichkeit (Felt Responsibility; B3). Parallel dazu wird Invisibility über die Anzahl interpersonaler Hinweisreize (NIC; C1/E) operationalisiert. Mehr Hinweisreize erhöhen die Sorge um den Eindruck bei anderen (Concern about impression on others; D) und reduzieren dadurch die Ausdrucksbereitschaft (Courage to express oneself; F). Eine cue-arme Kommunikationssituation führt entsprechend zu geringerer CAI und höherer CE. Beide Pfade wirken gemeinsam auf State Disinhibition als situative Tendenz zu enthemmtem Online-Verhalten (A). Zusätzlich wird MOD als exogene Dispositionsvariable berücksichtigt, die interindividuelle Unterschiede in der allgemeinen Disinhibitionstendenz abbildet (G). Als beobachtbarer Verhaltensindikator wird in dieser Arbeit exemplarisch der Schimpfwortanteil (Curse) verwendet (H). Im nächsten Schritt wird diese prototheoretische Prozesskette in ein formales Modell überführt; wo die Originalliteratur keine eindeutige Funktionsform vorgibt, werden Zusatzannahmen explizit gemacht und begründet.

Entwicklung eines formalen Modells

Open materials and code: GitHub repository

Ziel der formalen Modellierung ist es, die im VAST dargestellten gerichteten Zusammenhänge als explizite Funktionen zu spezifizieren, um das Verhalten des Gesamtsystems psi simulieren zu können. Für jede endogene Variable wird daher eine Rechenvorschrift definiert, die alle eingehenden Pfeile

als Input verwendet (vgl. Relationship Table, Appendix C). Wo Suler (2004) keine Funktionsform vorgibt, werden Zusatzannahmen so gewählt, dass sie die im VAST dargestellte Wirkungsrichtung abbilden, die definierten Wertebereiche respektieren (Appendix B) und numerisch stabil sind.

Theoriegeleitete Teilbeziehungen (Invisibility-Zweig)

Entsprechend der Operationalisierung von Invisibility über die Anzahl interpersonaler Hinweisreize (NIC; E) wird *Concern about impression on others* (CAI) direkt durch NIC modelliert:

$$\mathrm{CAI} = \mathrm{NIC}$$

Courage to express oneself (CE) wird als inverser Zusammenhang zu CAI modelliert:

$$\mathrm{CE} = 1 - \mathrm{CAI}$$

Damit wird formal umgesetzt, dass mehr Hinweisreize zu höherer CAI und damit zu geringerer Ausdrucksbereitschaft führen.

Modellannahmen zur Formalisierung des Anonymity-Zweigs

Für den Dissociative-Anonymity-Zweig beschreibt Suler den Mechanismus inhaltlich, aber nicht funktional. Um eine graduelle, nichtlineare Zunahme von *Identity compartmentalization* (IC) mit steigender Anonymität (AN) abzubilden, wird folgende S-förmige Transformation verwendet:

$$\mathrm{IC} = \frac{\mathrm{AN}^2}{\mathrm{AN}^2 + (1 - \mathrm{AN})^2}$$

Felt Responsibility (FR) wird anschließend als abnehmende Funktion von IC modelliert und zusätzlich durch einen personenabhängigen Parameter *base_resp* skaliert:

$$\mathrm{FR} = \mathrm{base_resp} \cdot (1 - 0.8 \cdot \mathrm{IC})^3$$

Damit wird abgebildet, dass hohe IC mit geringerer Verantwortlichkeit einhergeht; *base_resp* bildet interindividuelle Unterschiede in der Grundverantwortlichkeit ab und stellt eine bewusste Modellergänzung dar.

Aggregation zu State Disinhibition (ψ)

Die zentrale psi-Funktion bildet *State Disinhibition* als lineare Kombination aus MOD, FR und CE ab, ergänzt um einen Interaktionsterm:

$$\mathrm{StateDis} = 0.2 \cdot \mathrm{MOD} - 0.3 \cdot \mathrm{FR} + 0.2 \cdot \mathrm{CE} - 0.1 \cdot (\mathrm{FR} \cdot \mathrm{CE})$$

Höhere MOD- und CE-Werte erhöhen, höhere FR-Werte senken die Disinhibition.

Abbildung des beobachtbaren Outcomes (Curse)

Zur Kopplung an ein beobachtbares Verhaltensmaß wird *StateDis* zunächst linear auf den Wertebereich ([0,1]) transformiert und anschließend um eine Zufallskomponente ergänzt:

$$\text{Curse} = \frac{\text{StateDis} + 0.1}{1.3} + \varepsilon, \quad \varepsilon \sim \mathcal{N}(0,\, 0.1)$$

Anschließend wird *Curse* auf ([0,1]) begrenzt. Die Zufallskomponente modelliert nicht erklärte interindividuelle Varianz sowie Mess- und Situationsrauschen und stellt ebenfalls eine explizite Modellannahme dar.

Visualisierung der funktionalen Beziehungen

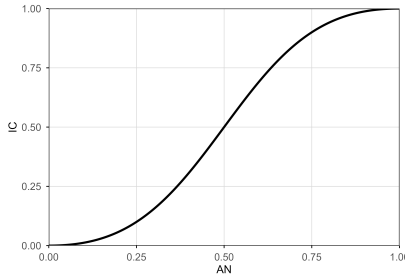

(a) Mit steigender Anonymität nimmt IC nichtlinear zu; der stärkste Zuwachs liegt im mittleren AN-Bereich.

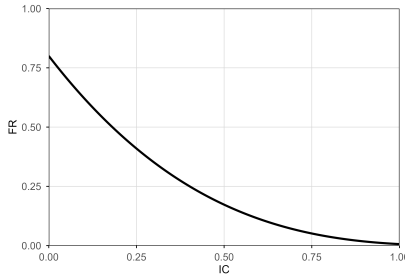

(b) FR sinkt mit zunehmender IC stark und nichtlinear (hier bei base_resp = 0.8).

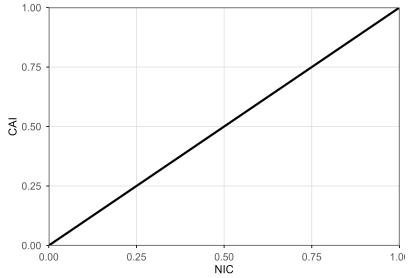

(c) CAI steigt linear mit NIC: mehr Hinweisreize bedeuten mehr Sorge um den Eindruck.

Abbildung 2: Visualisierung der funktionalen Beziehungen I (vgl. Appendix C).

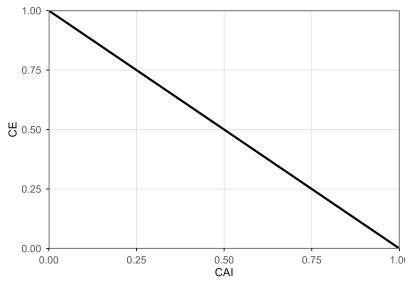

(a) CE sinkt linear mit CAI: je stärker die Eindruckssorge, desto geringer die Ausdrucksbereitschaft.

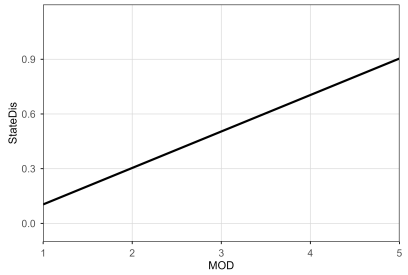

(b) Bei konstantem FR und CE steigt StateDis monoton mit MOD.

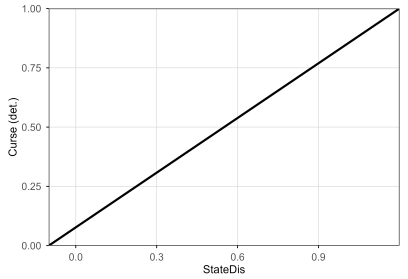

(c) Curse wird als lineare Skalierung von StateDis auf den Wertebereich [0,1] abgebildet.

Abbildung 3: Visualisierung der funktionalen Beziehungen II (vgl. Appendix C).

Evaluation des formalen Modells

Baseline-Simulation: Interaktionsmuster AN × NIC/cues

Zur ersten Plausibilitätsprüfung wurde das Basismodell auf einem 3×3-Grid simuliert (AN $\{0, 0.5, 1\}$, NIC/cues $\{0, 0.5, 1\}$). Abbildung 4 zeigt die Zellmittelwerte von *Curse* für n = 900. Das erwartete Muster wird reproduziert: *Curse* steigt mit AN, sinkt mit NIC/cues, und der höchste Wert zeigt sich in der Kombination aus hoher Anonymität und niedriger Hinweisreiz-Dichte. Damit werden H1–H3 im Basismodell zunächst auf visueller Ebene unterstützt.

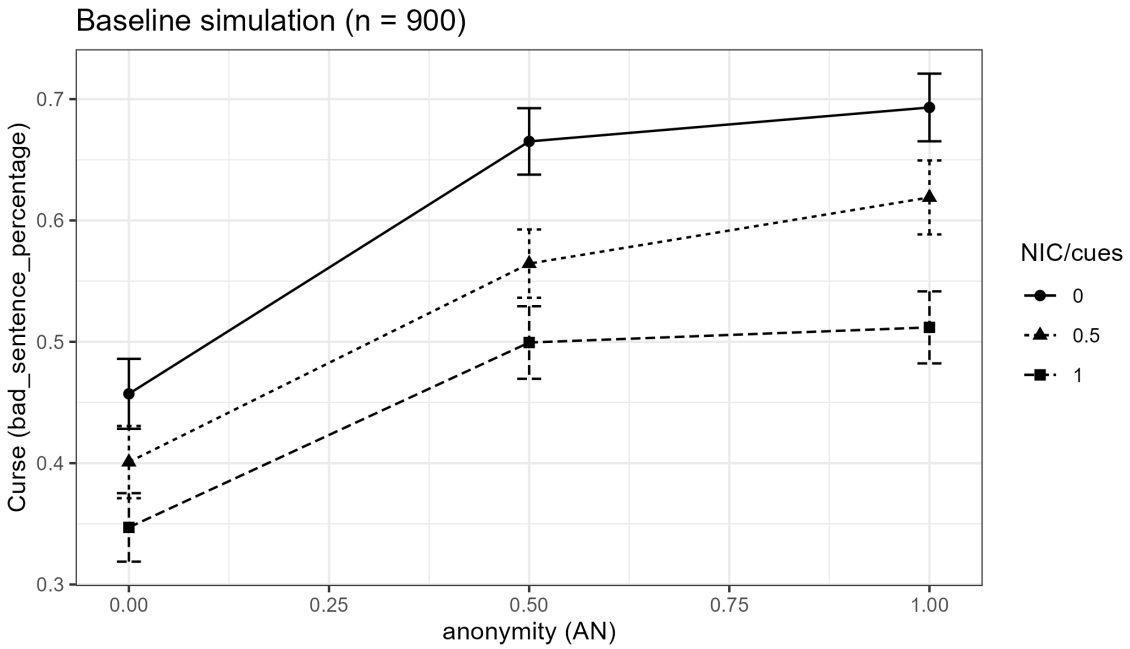

Abbildung 4: Baseline-Simulation (n = 900): Interaktionsplot der Zellmittelwerte von *Curse* über Anonymität (AN), getrennt nach NIC/cues.

Quantitative Prüfung der Baseline-Hypothesen

Zur quantitativen Einordnung des Baseline-Musters wird zusätzlich der 2×2-Extremvergleich zwischen AN hoch, NIC niedrig und AN niedrig, NIC hoch betrachtet. Der mittlere *Curse*-Wert liegt in der Extrembedingung um $M = 0.35$ Punkte höher; dies entspricht einem Effekt von Cohen's $d = 2.42$. Damit wird das erwartete Basismuster nicht nur visuell, sondern auch durch einen klar interpretierbaren numerischen Effekt gestützt. Zusätzlich wurde das simulierte Basismodell mit einem linearen Modell der Form Curse ~ AN × NIC/cues ausgewertet. Da AN und NIC/cues im Simulationsdesign systematisch vorgegeben wurden, ist diese Auswertung als interner Modellcheck und nicht als empirische Inferenz zu verstehen.

Wie erwartet zeigte die Auswertung des großen 3×3-Datensatzes klare Haupt- und Interaktionseffekte im erwarteten Muster. Damit werden H1–H3 im Basismodell nicht nur visuell, sondern auch auf Ebene des linearen Modellchecks unterstützt.

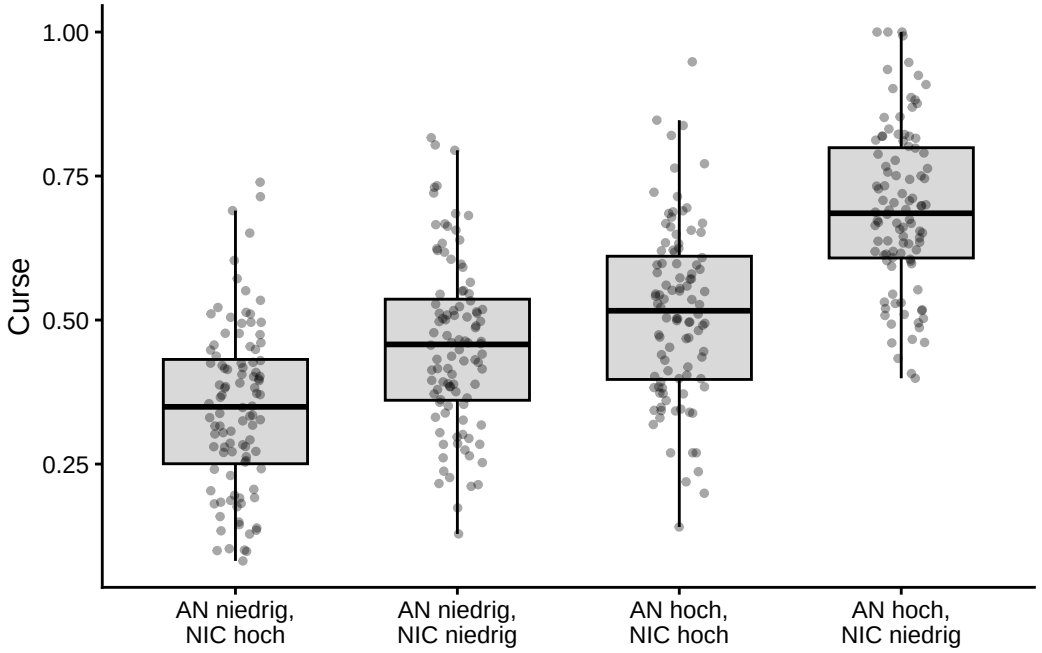

Abbildung 5: Simulierte Rohdaten im 2×2-Extremvergleich. Gezeigt ist die Verteilung von *Curse* für die vier Bedingungen aus Anonymität (AN: niedrig vs. hoch) und Hinweisreiz-Dichte (NIC/cues: niedrig vs. hoch). Niedrige NIC-Werte entsprechen hoher Invisibility.

In Abbildung 5 zeigt sich das erwartete Muster: Die höchsten *Curse*-Werte treten in der Bedingung AN hoch, NIC niedrig auf, während die Referenzbedingung AN niedrig, NIC hoch die niedrigsten Werte zeigt. Damit ist der Extremkontrast auch auf Ebene der simulierten Einzelbeobachtungen sichtbar.

Explorative Robustheitsanalyse: Assumption Tournament × UTOS-in-code

Über die Baseline hinaus wurde geprüft, ob die Reproduktion des Zielphänomens von einzelnen Modellannahmen abhängt. Dazu wurde für die Beziehung CAI → CE ein Assumption Tournament mit drei plausiblen Spezifikationen durchgeführt: einer linearen, einer abgeschwächt linearen und einer nichtlinearen bzw. thresholdartigen Variante.

Ergänzend wurde die Generalisierbarkeit des Musters exemplarisch im Sinne des UTOS-Frameworks als UTOS-in-code operationalisiert. Dabei wurden Units über unterschiedliche Verteilungen von *base_resp*, Settings über die Stabilität der Hinweisreiz-Dichte sowie MOD über lowMOD- und highMOD-Szenarien variiert. Als kompaktes Evaluationsmaß diente ein virtuelles 2×2-Extremvergleichsdesign, in dem die Differenz (= M_{HH} - M_{LL}) zwischen der extremen Bedingung hoher Anonymität und hoher Invisibility und der Referenzbedingung niedriger Anonymität und niedriger Invisibility berechnet wurde.

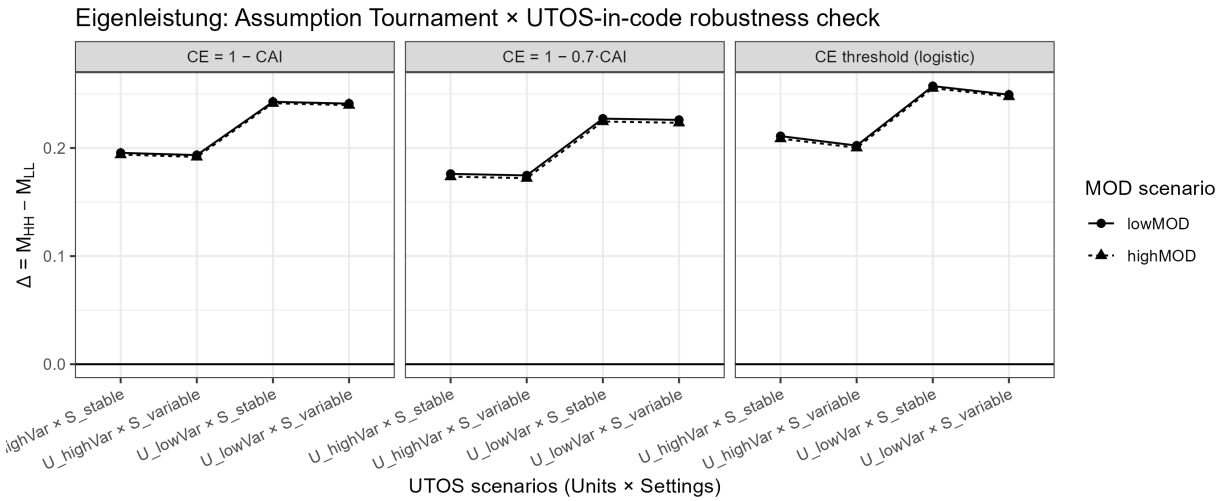

Abbildung 6: Eigenleistung: Robustheitsanalyse via Assumption Tournament × UTOS-in-code-Szenarien. Der Effekt wird über $\Delta = M_{HH} - M_{LL}$ quantifiziert; höhere Werte zeigen eine stärkere Reproduktion des Zielphänomens an. Die Panels vergleichen alternative Formalisierungen des CAI→CE-Zusammenhangs; die Linien vergleichen MOD-Szenarien (lowMOD vs. highMOD) über UTOS-Szenarien (Units × Settings).

Abbildung 6 zeigt, dass der Extremkontrast über alle geprüften Annahmen- und UTOS-Konfigurationen hinweg positiv bleibt, auch wenn seine Größe variiert. Das spricht dafür, dass die Phänomenreproduktion nicht bloß ein Artefakt einer einzelnen Funktionsform oder eines einzelnen Kontext-Settings ist, sondern unter mehreren plausiblen Modellvarianten erhalten bleibt. Zugleich reagiert die Stärke der Reproduktion sensitiv auf Modellierungsentscheidungen und Kontextannahmen. Die Robustheitsanalyse stützt damit weniger eine punktgenaue Effektgrößenschätzung als die strukturelle Plausibilität des formalisierten Teilmodells.

Diskussion: Meta-Reflexion

Die Formalisierung des Online-Disinhibition-Effekts (Suler, 2004) hat mich insgesamt positiv überrascht. Zu Beginn hatte ich deutliche Zweifel, ob ich den methodischen Anforderungen des Projekts – VAST, Tabellen, Simulation und reproduzierbarer Workflow – gewachsen bin. Im Verlauf wurde jedoch klar, dass die einzelnen Schritte sinnvoll aufeinander aufbauen und der Prozess gerade durch die iterative Logik (VAST → Tabellen → Funktionen → Simulation → Evaluation) zunehmend greifbar wird. Hilfreich waren dabei sowohl die offene Fehlerkultur im Seminar als auch die Zusammenarbeit in der Gruppe.

Gleichzeitig zeigte sich, dass Sulers Originaltext zwar ein guter Ausgangspunkt ist, für eine Formalisierung aber in Teilen zu vage bleibt. Zentrale Begriffe sind eher narrativ beschrieben als präzise definiert, sodass ein wesentlicher Teil der Arbeit darin bestand, Konstrukte zu schärfen und operationalisierbar zu machen, etwa Anonymität als kontinuierliche Größe oder Invisibility über die Anzahl interpersonaler Hinweisreize. Auch die Literaturrecherche war ambivalent: Für einige Zusammenhänge ließ sich Evidenz finden, insgesamt zeigte sich jedoch eine heterogene Befundlage, insbesondere für Anonymity. Hinzu kommt, dass viele Studien eher perceived anonymity als objektive

Anonymität erfassen, was die Vergleichbarkeit einschränkt. Deshalb waren an mehreren Stellen begründete Zusatzannahmen nötig, um das Modell überhaupt formal spezifizieren und simulieren zu können.

Am schwierigsten war für mich die Balance zwischen wissenschaftlicher Plausibilität und pragmatischer Modellierbarkeit. Funktionsformen müssen einfach genug sein, um interpretierbar zu bleiben, aber zugleich präzise genug, um ein prüfbares System zu ergeben. Genau darin lag aber auch der größte Lerngewinn: Formalisierung macht theoretische und messmethodische Lücken sichtbar und zwingt dazu, implizite Annahmen explizit zu machen. Aus dem Projekt nehme ich deshalb nicht nur konkrete technische Kompetenzen mit – etwa Quarto, GitHub und reproduzierbares Arbeiten –, sondern vor allem ein besseres Verständnis dafür, wie psychologische Theorien in ein transparentes und evaluierbares Modell überführt werden können.

Literaturverzeichnis

Christie, C., & Dill, E. (2016). Evaluating peers in cyberspace: The impact of anonymity. *Computers in Human Behavior*, *55*, 292–299.

Clark-Gordon, C. V., Bowman, N. D., Goodboy, A. K., & Wright, A. (2019). Anonymity and Online Self-Disclosure: A Meta-Analysis. *Communication Reports*, *32*(2), 98–111. https://doi.org/10.1080/08934215.2019.1607516

Lapidot-Lefler, N., & Barak, A. (2012). Effects of anonymity, invisibility, and lack of eye-contact on toxic online disinhibition. *Computers in Human Behavior*, *28*(2), 434–443. https://doi.org/10.1016/j.chb.2011.10.014

Suler, J. (2004). The online disinhibition effect. *CyberPsychology & Behavior*, *7*(3), 321–326. https://doi.org/10.1089/1094931041291295

Wang, L., Jiang, S., Zhou, Z., Fei, W., & Wang, W. (2024). Online disinhibition and adolescent cyberbullying: A systematic review. *Children and Youth Services Review*, *156*, 107352. https://doi.org/10.1016/j.childyouth.2023.107352

Appendix

Appendix A: Construct Source Table

Reference	Quote	Extracted element (Concept or relationship)	Element type **(Concept or Relation-ship)**	**Rel. type (n, p, i, r, c, ...)**	**Short name / associated concept**	**Comment**	**ID**
Suler, J. (2004)	"people say and do things in cyberspace that they wouldn't ordinarily say and do in the face-to-face world. They loosen up, feel less restrained, and express themselves more openly."	State Disinhibition	C	n	StateDis		A
Suler, J. (2004)	"When people have the opportunity to separate their actions online from their in-person lifestyle and identity, they feel less vulnerable about self-disclosing and acting out. [...] The online self becomes a compartmentalized self."	Anonymity	C	n	AN	characteristic of cyberspaces	B1
		Identity Compart-mentalisation	C	n	IC		B2
		Felt Responsibility	C	n	FR		B3
		Dissociative Anonymity	HOC	n	DisAn		B4
Suler, J. (2004)	"In many online environments, especially those that are text-driven, people cannot see each other. When people visit web sites, message boards, and even some chat rooms, other people may not even know they are present at all"	Invisibility	HOC	n	Inv	characteristic of cyberspaces	C1
Suler, J. (2004)	"Avoiding eye contact and face-to-face visibility disinhibits people. Text communication offers a built-in opportunity to keep one's eyes averted."	Number of interpersonal cues	C	n	NIC		E
Suler, J. (2004)	"People don't have to worry about how they look or sound when they type a message. They don't have to worry about how others look or sound in response to what they say. Seeing a frown, a shaking head, a sigh, a bored expression, and many other subtle and not so subtle signs of disapproval or indifference can inhibit what people are willing to express."	Concern about impression on others	C	n	CAI		D
Suler, J. (2004)	"This invisibility gives people the courage to go places and do things that they otherwise wouldn't"	Courage to express oneself			CE		F
Stuart and Scott, 2021	"Using two studies with unique samples, the Measure of Online Disinhibition (MOD), was developed as a comprehensive and valence free instrument for assessing self-perceptions of psychological and behavioral change in the online as compared to the offline environment."	Measure of online disinhibition	C	n	MOD	trait online-disinhibition	G
		Percentage of curse words	C	n	Curse	Percentage of sentences that contain at least one curse word	H

Appendix B: Variable Table

Construct	Short Name	Scale level	exogen/endogen	Range/Values	Anchors
Anonymity	AN	continuous	exogen	[0;1]	0 = User is fully known during the interaction; 1 = Full anonymity where the user remains unknowable during the interaction
Identity compartmentalization	IC	continuous	endogen	[0;1]	0 = online- and offline-self are completely identical; 1 = feeling like 'those online behaviors "aren't me at all."' (Suler, 2004)
Felt Responsibility	FR	continuous	endogen	[0;1]	0 = one feels no responsibility for one's actions, temporary suspension of moral cognitive processes; 1 = maximal feeling of responsibility for one's actions
Number of interpersonal cues	NIC	continuous	exogen	[0;1]	0 = text-only, minimal interpersonal cues; 1 = audio, video and nonverbal feedback, maximal nonverbal, paraverbal and verbal cues
Concern about impression on others	CAI	continuous	endogen	[0;1]	0 = not concerned about impression on others, 0.3 = mildly concerned about impression on others, 1 = maximal concerned about impression on others
Courage to express oneself	CE	continuous	endogen	[0;1]	0 = maximal inhibition and fear of expressing oneself; 1 = no fear of expressing oneself
Measure of online disinhibition	MOD	continuous	exogen	[1;5]	5-point likert scale; 1 = strongly disagree to 5 = strongly agree for the items of the MOD
State Disinhibition	StateDis	continuous	endogen	[-0.1;1.2]	-0.1 = no inclination to "say and do things in cyberspace that they wouldn't ordinarily say and do in the face-to-face world" (Suler, 2004); 1.2 = maximal inclination toward such behavior
Percentage of curse words	Curse	continuous	endogen	[0;1]	0 = no sentence containing any curse word; 1 = every sentence contains at least one curse word

Appendix C: Relationship Table

Output variable	Function	Comment	Derived from theory?	Evidence
IC	$IC = (AN^2) / (AN^2 + (1-AN)^2)$	positive, S-shaped relationship	Not based on focal theory, but rather on common sense or other theories	indications, but no robust empirical evidence
FR	$FR = \text{base response} \times (1 - 0.8 \times IC)^3$	base resp: base responsibility, included as model parameter, describes a person's trait responsibility, varies inter-individually	Not based on focal theory, but rather on common sense or other theories	indications, but no robust empirical evidence
CAI	CAI = NIC	positive linear relationship interpersonal cues as independent variable	Derived from theory	
CE	CE = - CAI + 1	negative linear relationship	Derived from theory	
StateDis	$StateDis = 0.2 \times MOD - 0.3 \times FR + 0.2 \times CE - 0.1 \times FE \times CE$		Loosely inspired by theory, with added elements based on common sense and other theories	no evidence for this specific relationship
Curse	Curse = (StateDis + 0.1) / 1.3	+ rnorm(length(StateDis), mean = 0, sd = 0.1) to add random noise/interpersonal variance	Not based on focal theory, but rather on common sense or other theories	no evidence for this specific relationship